Dynamics에 적응하는 잠재 Actor-Critic: 잠재 변수 모델을 가진 효율적인 심층 강화학습

이동민, 정창훈, 장병탁
서울대학교 컴퓨터공학부
{dmlee, chjeong, btzhang}@bi.snu.ac.kr

Dynamics-adaptive Latent Actor-Critic: Efficient Deep Reinforcement Learning with a Latent Variable Model

Dongmin Lee, Changhoon Jeong, Byoung-Tak Zhang
Department of Computer Science and Engineering, Seoul National University

요 약

심층 강화학습 (deep reinforcement learning)은 상태 특징 (state feature)들로부터 직접적으로 학습하기 위해 대용량의 신경망 (neural network)을 사용한다. 그러나 상태 특징들에 대한 상태 공간은 심층 강화학습에서 정책 (policy)을 학습하는 데에 많은 어려움들을 야기한다. 실제로 기존의 심층 강화학습 알고리즘들을 원시 (raw) 상태 특징으로 학습할 때 매우 느리고, 하이퍼파라미터 (hyperparameter)에 민감하며, 샘플 비효율적 (sample inefficient)이다. 따라서 효과적인 상태 공간을 가지고 있어야 효율적인 탐험 (exploration)이 가능하며, 이로 인해 최적 정책 (optimal policy)을 빠르게 찾을 수 있다. 본 논문에서는 효과적인 상태 공간을 갖기 위해 상태 특징들로부터 환경의 dynamics에 적응하는 잠재 변수 모델을 사용하여 더 효율적인 심층 강화학습이 가능한 표현 학습 (representation learning) 방법을 제안한다. 제안하는 방법을 통해 OpenAI Gym의 LunarLander와 Hopper 환경에 대해 실험을 진행한 결과, 제안하는 방법이 기존에 존재하는 SOTA (state-of-the-art) 강화학습 알고리즘보다 훨씬 더 효율적이고 더 좋은 성능을 보임을 실험적으로 검증하였다.

1 서 론

심층 강화학습은 이미지나 센서 데이터와 같이 원시적이고, 낮은 레벨의 상태 특징으로부터 특정한 태스크를 자동적으로 학습한다. 최근 심층 강화학습은 광범위한 의사결정 문제부터 제어 태스크 문제 등 다양한 문제들에서 이러한 이미지나 센서 데이터를 통해 많은 성공을 이루었다 [1, 2, 3, 4, 5]. 그러나 상태 특징들에 대한 상태 공간은 심층 강화학습에서 정책을 학습하는 데에 많은 어려움들을 야기한다. 실제로 기존의 심층 강화학습 알고리즘들은 원시적이고, 낮은 레벨의 상태 특징으로부터 학습하면 학습이 매우 오래 걸리고, 하이퍼파라미터에 민감하며, 샘플 비효율적이다. 따라서 효과적인 상태 공간을 가지고 있어야 효율적인 탐험이 가능하며, 이로 인해 최적 정책을 빠르게 찾을 수 있다.

본 논문에서는 효과적인 상태 공간을 갖기 위해 상태 특징들로부터 환경의 dynamics에 적응하는 잠재 변수 모델을 사용하여 더 효율적인 심층 강화학습이 가능한 표현 학습 방법을 제안한다. 제안하는 방법에는 세 가지 장점이 존재한다. 첫 째, 잠재 변수 모델을 이용한 표현 학습은 유용한 잠재 상태 특징의 잠재 공간 (latent space)을 표현한다. 둘 째, 이러한 표현 학습을 이용한 잠재 공간에서의 심층 강화학습은 기존의 탐험 방법들보다 더 효과적인 탐험 방법을 가진다. 마지막으로, 강화학습에서 중요하게 고려해야할 점인 환경의 불확실성 (uncertainty) 문제를 해결할 수 있다. 만약 어떤 행동을 통해 현재 상태에서 다음 상태를 잘 예측하는 하나의 잠재 변수 모델을 사전에 학습할 수 있다면, 잠재 상태들에 대한 잠재 공간을 가진 모델은 상태 변수에 대한 불확실성을 나타낼 수 있기 때문에 적은 샘플만으로도 효율적인 강화학습이 가능하다.

이러한 모델을 갖추기 위해 우리는 간단하지만 매우 효과적인 변분적 추론 (variational inference) 기반 잠재 상태의 표현 학습 방법론을 제안한다. 제안하는 방법을 통해 OpenAI Gym의 LunarLander와 Hopper 환경에 대해 실험을 진행한 결과, 사전 표현 학습된 잠재 공간에서 강화학습을 진행하는 것이 기존에 존재하는 SOTA 강화학습 알고리즘보다 훨씬 더 효율적이며 더 좋은 성능을 보임을 검증하였다.

2 배경 지식

우리는 강화학습 문제 정의를 위해 마르코프 결정 과정 (markov decision process)을 튜플 (S, A, p, r, γ)로 정의한다. 상태 공간 S와 행동 공간 A는 연속적이며, 알려지지 않은 상태 전이 확률 (transition probability) $p : S \times A \times S \to \mathbb{R}_+$는 상태 $s \in S$와 행동 $a \in A$가 주어질 때 다음 상태 $s' \in S$의 확률 밀도를 나타낸다. $r : S \to \mathbb{R}$은 보상 함수 (reward function)이고, $\gamma \in (0, 1)$ 은 할인인자 (discount factor)이다. 정책 $\pi(a|s)$은 상태가 주어졌을 때 행동에 대한 하나의 확률적 정책 (stochastic policy)으로 정의하고, $\mathbb{P}_0 : S \to R_+$는 초기 상태 s_0의 분포로 정의한다. 에이전트는 매 타임 스텝 (time step)마다 상태 s_t로부터 정책 $\pi(a_t|s_t)$를 통해 행동 a_t를 취하고 확률적 전이 (stochastic transition) dynamics $p(s_{t+1}|s_t, a_t)$에 따라 다음 상태 s_{t+1}로 도달한다.

이러한 정의로부터 강화학습의 목표는 수식 (1)과 같이 매 타입 스텝마다 정책 $\pi(a_t|s_t)$으로부터 할인된 미래 보상들의 합의 기댓

값을 최대화하는 것이다.

$$\max_{\pi} \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty} \gamma^{t} r(s_t, a_t)\right] \tag{1}$$

우리는 또한 샘플링이 가능한 확률분포를 정의한다. $\mathbb{P}^{\pi}_{SAS'}$는 $s_0 \sim \mathbb{P}_0(s_0)$로 시작하여 정책 π를 따르는 튜플 (s, a, s')의 결합 확률분포 (joint probability distribution) 이고, $\mathbb{P}^{\pi}_{SS'} = \int_A d\mathbb{P}^{\pi}_{SAS'}$와 $\mathbb{P}^{\pi}_{A} = \int_{S\times S'} d\mathbb{P}^{\pi}_{SAS'}$는 각각 상태와 행동에 대한 주변확률분포 (marginal probability distribution)로 정의된다.

3 잠재 변수 모델과 강화학습

3.1 잠재 변수 모델의 설계와 학습

우리는 VAE [6] 또는 $\beta - VAE$ [7]의 변분적 추론 아이디어를 활용하여 사전 학습된 잠재 변수 모델을 사용한다. 먼저, 환경에서 무작위 정책 (random policy)을 통해 얻어진 튜플 (s, a, s')에 대한 결합확률분포 $\mathbb{P}^{\pi}_{SAS'}$를 구축하고, 이에 대한 주변확률분포 $\mathbb{P}^{\pi}_{SS'}$와 $\mathbb{P}^{\pi}_{A}$를 각각 구축한다.

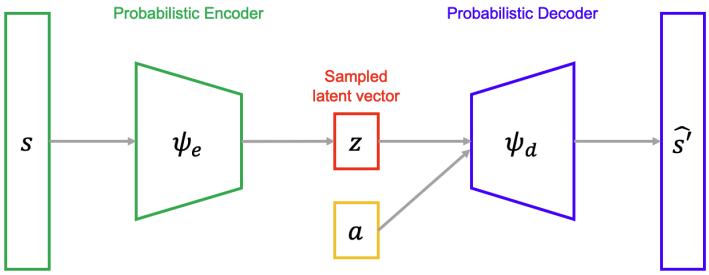

그림 1: 잠재 변수 모델의 계산적 아키텍쳐

제안하는 학습 모델은 상태 s를 잠재 벡터 $z \in Z$로 임베딩하는 인코더 $\psi_e(z|s)$를 학습한다. 이러한 인코딩은 dynamics $p(s'|s, a)$의 충분한 통계량 (sufficient statistics)을 최대한 효과적으로 표현하기 위해 최적화되므로 $p(s'|s, a) \approx p(s'|z, a)$가 된다.

그림 1은 잠재 변수 모델의 구조를 보여준다. $\mathbb{P}^{\pi}_{SS'}$에서 샘플링된 상태 s는 확률적 인코더 $\psi_e(z|s)$의 입력으로 들어가서 샘플링된 잠재 벡터를 출력하게 되고, z와 $\mathbb{P}^{\pi}_{A}$에서 샘플링된 a는 디코더 ψ_d의 입력으로 들어가서 다음 상태의 예측 값인 $\hat{s}'$을 출력한다. 우리는 뒤따르는 수식 (2)의 목적 함수를 최소화함으로써 $p(s'|z, a)$를 $p(s'|s, a)$로 근사시킨다.

$$J_M(\psi) := \mathbb{E}_{s,s'\sim\rho^{\pi}}\left[\parallel \hat{s}' - s' \parallel_2^2 + \beta D_{KL}\Big(\psi_e(s) \parallel \mathcal{N}(0, \boldsymbol{I})\Big)\right] \tag{2}$$

수식 (2)의 ρ^{π}는 정책 π으로부터의 확률적 전이 dynamics의 분포이다. 수식 (2)의 목적 함수는 $\beta - VAE$ [7]의 목적 함수와 비슷하지만, 목적상 다른 변분적 추론 기반의 목적 함수이다. 해당 목적 함수는 잠재 변수 모델의 출력 값으로 나온 $\hat{s}'$과 실제 정답인 다음 상태 s'을 최소화하는 $\parallel \hat{s}' - s' \parallel_2^2$와 하이퍼파라미터 β 계수를 이용하여 상태 s를 인코딩한 $\psi_e(s)$가 정규분포 $\mathcal{N}(0, \boldsymbol{I})$와 멀어지지 않도록 압축 및 유지하는 $\beta D_{KL}\Big(\psi_e(s) \parallel \mathcal{N}(0, \boldsymbol{I})\Big)$으로 이루어진다. 여기서 β는 VAE [6] 또는 $\beta - VAE$ [7]와는 다르게 0.0001로 고정시켰을 때 더 좋은 성능을 보였으며 4장에서 제시한 실험에서 모두 고정된 β값을 사용하였다.

3.2 잠재 변수 모델을 이용한 효율적인 강화학습

3.1에서 제안한 잠재 변수 모델의 학습이 끝나면, 사전 학습된 모델의 인코더를 이용하여 강화학습을 진행한다. 우리는 강화학습 알고리즘으로 off-policy 알고리즘인 SAC (soft actor-critic) [3, 4]을 사용하였다. SAC의 학습은 수식 (3)와 같이 파라미터 ϕ로 나타낸 정책 π_{ϕ}에 대한 Soft Q-함수 Q_{θ}를 갱신하는 Critic의 목적 함수와 수식 (4)와 같이 Critic의 평가된 값을 사용하여 정책 π_{ϕ}을 갱신하는 Actor의 목적 함수를 최소화함으로써 학습된다.

$$J_Q(\theta) := \mathbb{E}_{(z_t,a_t)\sim D}\left[\frac{1}{2}\Big(Q_{\theta}(z_t, a_t) - [r(z_t, a_t) + \gamma \mathbb{E}_{z_{t+1}} V_{\bar{\theta}}(z_{t+1})]\Big)^2\right] \tag{3}$$

$$J_{\pi}(\phi) := \mathbb{E}_{z_t\sim D}\Big[\mathbb{E}_{a_t\sim\pi_{\phi}}[\alpha \log \pi_{\phi}(a_t|z_t) - Q_{\theta}(z_t, a_t)]\Big] \tag{4}$$

여기서 D는 리플레이 버퍼 (replay buffer)이며, $V_{\bar{\theta}}$는 타겟 가치 네트워크이다. 기존의 SAC 알고리즘과는 다르게, 사전 학습된 모델의 인코더 $\psi_e(z_t|s_t)$를 통해 상태 s_t를 입력으로 하여 나온 dynamics에 적응된 유용한 잠재 상태 z_t가 Actor와 Critic 각각 목적 함수에 s_t를 대신하여 사용된다.

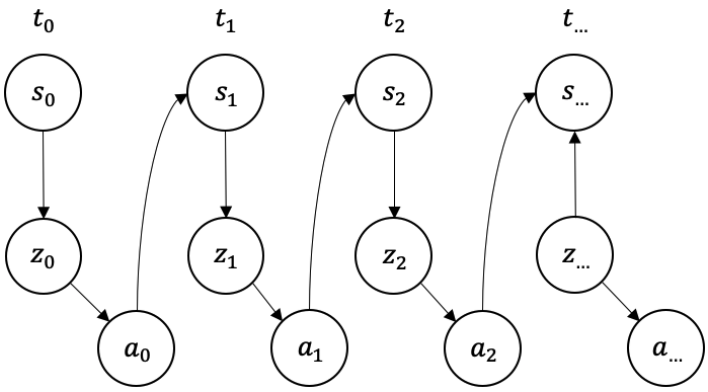

그림 2: 잠재 상태를 이용한 강화학습의 그래피컬 모델

우리는 잠재 변수 모델을 이용한 그래피컬 모델을 그림 2로 나타내었다. 그림과 같이, 원시 상태가 아닌 환경의 dynamics에 적응하는 유용한 잠재 상태를 통해 행동을 결정하고, 그 행동으로 다음 상태에 도달한다. 계속해서, 매 타임 스텝마다 잠재 상태를 통해 강화학습을 진행하면 더 효과적인 탐험 방법을 가질 수 있기 때문

에 기존의 원시 상태를 통해 강화학습을 진행하는 것보다 더 샘플 효율적 (sample efficient)이다.

4 실험 결과

OpenAI Gym [8]의 LunarLander-v2와 Hopper-v2 각각의 환경에 대해 사전에 잠재 변수 모델의 학습을 진행한 후에 강화학습 실험을 진행하였다. SAC의 엔트로피 계수 α는 LunarLander-v2와 Hopper-v2 각각 0.3, 0.2으로 설정하여 실험을 진행하였다.

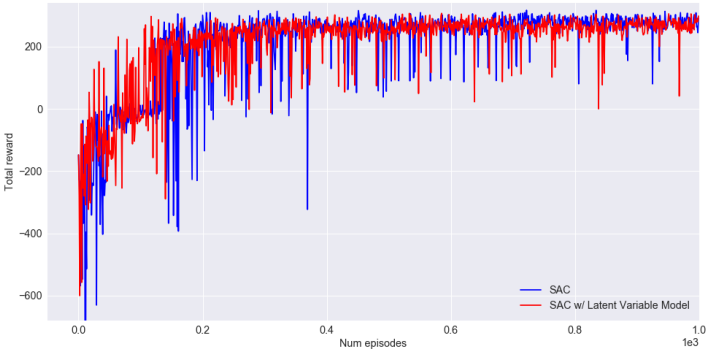

그림 3: LunarLander-v2 환경 실험 결과

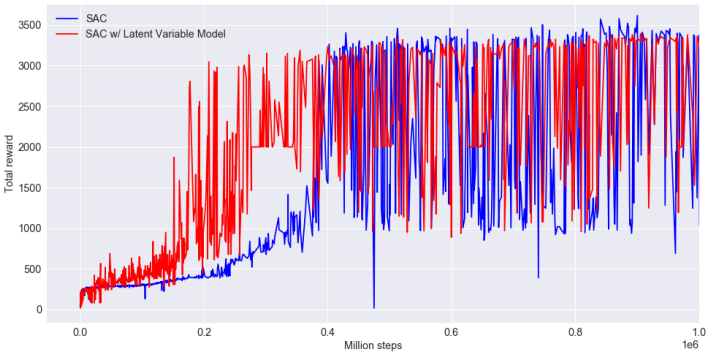

그림 4: Hopper-v2 환경 실험 결과

우리는 그림 3와 그림 4의 결과를 통해 LunarLander-v2와 Hopper-v2의 성능을 에피소드 (episode) 또는 스텝 (step) 대비 총 보상 (total reward)으로 나타내었다. 위 실험 결과, 두 환경 모두 사전 표현 학습된 잠재 변수 모델을 이용한 SAC 에이전트 (red)가 기존의 존재하는 SOTA인 SAC 에이전트 (blue)보다 더 좋은 성능을 보였고, 특히 Hopper-v2는 압도적인 성능을 보였다.

5 결론 및 향후 연구

본 논문에서 우리는 환경의 dynamics에 적응하는 잠재 변수 모델을 사용하여 효율적인 심층 강화학습이 가능한 표현 학습 방법을 제안하였다. 제안한 방법은 매우 간단하면서도 유용한 잠재 상태의 잠재 공간을 학습할 수 있었고, 사전 학습된 모델의 인코더를 이용한 SAC 알고리즘의 실험을 통해 이를 검증할 수 있었다. 향후 연구로는 더 크고 복잡한 환경에 대한 실험을 진행하고, 추가적으로 더 효과적인 탐험 방법과 환경의 불확실성을 더욱 효과적으로 낮출 수 있는 방법론을 연구할 예정이다.

6 감사의 글

이 논문은 2020년도 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원(2019-0-01367-BabyMind, 2015-0-00310-SW.StarLab, 2017-0-01772-VTT, 2018-0-00622-RMI), 한국산업기술진흥원(P0006720-GENKO)의 지원을 받았음

참고 문헌

[1] V. Mnih, K. Kavukcuoglu, D. Silver, A. Graves, I. Antonoglou, D. Wierstra, and M. Riedmiller, "Playing atari with deep reinforcement learning," *arXiv preprint arXiv:1312.5602*, 2013.

[2] O. M. Andrychowicz, B. Baker, M. Chociej, R. Jozefowicz, B. McGrew, J. Pachocki, A. Petron, M. Plappert, G. Powell, A. Ray, *et al.*, "Learning dexterous in-hand manipulation," *The International Journal of Robotics Research*, vol. 39, no. 1, pp. 3–20, 2020.

[3] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, "Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor," *arXiv preprint arXiv:1801.01290*, 2018.

[4] T. Haarnoja, A. Zhou, K. Hartikainen, G. Tucker, S. Ha, J. Tan, V. Kumar, H. Zhu, A. Gupta, P. Abbeel, *et al.*, "Soft actor-critic algorithms and applications," *arXiv preprint arXiv:1812.05905*, 2018.

[5] D. Kalashnikov, A. Irpan, P. Pastor, J. Ibarz, A. Herzog, E. Jang, D. Quillen, E. Holly, M. Kalakrishnan, V. Vanhoucke, *et al.*, "Qt-opt: Scalable deep reinforcement learning for vision-based robotic manipulation," *arXiv preprint arXiv:1806.10293*, 2018.

[6] D. P. Kingma and M. Welling, "Auto-encoding variational bayes," *arXiv preprint arXiv:1312.6114*, 2013.

[7] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed, and A. Lerchner, "beta-vae: Learning basic visual concepts with a constrained variational framework.," *Iclr*, vol. 2, no. 5, p. 6, 2017.

[8] G. Brockman, V. Cheung, L. Pettersson, J. Schneider, J. Schulman, J. Tang, and W. Zaremba, "Openai gym," *arXiv preprint arXiv:1606.01540*, 2016.